

Faro — modelos pequeños con la ética dentro de los pesos para hardware antiguo

Informe técnico · v1 · 14 de septiembre de 2026

Proyecto Siliceo — Alfonso Riva

Artefactos y resultados en bruto: `state/faro/` (informes F0-F6, scripts, `bench-banco/`, `paper/`)

Resumen

Describimos *Faro*, una familia de modelos de instrucción de ≤ 2 GB (q4_k_m) diseñados para funcionar en una **GPU antigua de 4 GB** como mente local de un asistente siempre activo. La restricción de diseño es inusual: **ninguna capa de guardarraíles externos** — las reglas de comportamiento (una constitución, *Candela*) y un método de trabajo viven **dentro de los pesos**. Presentamos una canalización reproducible — poda multilingüe del vocabulario (IT/ES/EN), redimensionado de embeddings, continued pre-training constitucional (CPT), ajuste fino supervisado (SFT) sobre trazas de dominio, export GGUF — y la aplicamos *sin cambios* a cuatro arquitecturas de familias distintas: Qwen3.5-2B, MiniCPM5-2B, LFM2.5-2.6B y gemma-4-E2B. En un banco de 112 preguntas de dominio los modelos entrenados obtienen **86,6 / 84,8 / 83,9 / 72,3 %** frente al 55,4 / 55,4 / 61,6 / 56,2 % de sus bases (de +16 a +31 puntos). Todos caben en el presupuesto de tamaño y se sirven desde pesos cuantizados; uno exporta tool calls nativas. Reportamos una sonda ética de 16 casos sobre los modelos servidos, medidas de despliegue sobre el hardware objetivo (una GTX 1650) y discutimos los límites con honestidad: evaluaciones de una sola ejecución, sin ablaciones por componente todavía, y un banco específico del dominio con puntuación por reglas.

1. Introducción

Los modelos de lenguaje pequeños suelen evaluarse como *generalistas reducidos*. Nuestro contexto es distinto: un **asistente local-first** que debe funcionar de forma continua en hardware que una familia ya posee (una GTX 1650 de 4 GB), sin llamadas a la nube, y cuyos errores importan — no debe **mentir**: citar de dónde viene el conocimiento, rechazar con honestidad lo que no sabe hacer y no inventar nunca una fuente.

La práctica del estado del arte emparejaría un modelo pequeño con guardarraíles externos. Nosotros sostenemos lo contrario para esta clase de despliegues: el contrato de comportamiento debe estar **en los pesos** — parte de lo que el modelo es, no un filtro delante de él. Es a la vez una elección filosófica (la ética del asistente no es un middleware)

y de ingeniería: en una GPU de 4 GB no hay espacio, latencia ni presupuesto de mantenimiento para un segundo sistema.

Este informe documenta el proyecto *Faro*: una canalización para construir asistentes de dominio de ≤ 2 GB y su aplicación a cuatro arquitecturas de pesos abiertos. Contribuciones:

1. **Una receta reproducible** para asistentes bajo los 2 GB: poda multilingüe (IT/ES/EN) del vocabulario → redimensionado de embeddings → CPT constitucional → SFT sobre trazas → export GGUF → servicio local.
2. **Ética en los pesos**: constitución y procedimiento se entrenan vía CPT+SFT; ningún guardarraíl externo se usa en inferencia.
3. **Un estudio sobre cuatro modelos** de familias arquitectónicas distintas (Qwen denso, MiniCPM tipo-Llama, el híbrido LFM2, Gemma 4 derivado multimodal), con datos e hiperparámetros idénticos.
4. **Evidencia de despliegue**: los modelos ejecutan los flujos reales del asistente sobre el hardware objetivo, con velocidad y memoria medidas.

Somos explícitos sobre el alcance: este es un **informe de ingeniería**, no una contribución teórica nueva. El banco es nuestro, las ejecuciones son únicas y las ablaciones por componente son trabajo futuro (§7).

2. Trabajos relacionados

Adaptación del vocabulario. Podar o adaptar vocabularios multilingües es un eje de compresión consolidado. Ushio et al. [1] muestran que un vocabulario multilingüe puede *podarse* hacia una lengua objetivo manteniendo el rendimiento, reduciendo a la práctica mitad el tamaño de los embeddings. Purason et al. [2] proponen el pruning leaf-based (recorte consciente de la estructura) junto con continued BPE training, subrayando que en los modelos pequeños son precisamente los embeddings los que dominan el tamaño. VRCP [3] sustituye el vocabulario y continúa el pre-entrenamiento para entornos con recursos limitados; la adaptación cross-lingüe tokenizer-aware [4] usa una estrategia prune-with-extension; el token pruning para el coreano [5] reporta ganancias de estabilidad de generación y valida el pruning como optimización para despliegues de dominio con memoria limitada; estudios afines de pruning multilingüe aparecen en [6, 7]. Nuestra receta aplica esta línea práctica a un presupuesto de despliegue duro (≤ 2 GB) sobre cuatro familias de arquitecturas, y mide su efecto aguas abajo, sobre la tarea de dominio, en el artefacto servido.

Ajuste fino constitucional y ético. Constitutional AI [8] alinea modelos con ciclos crítica-revisión-preferencias respecto a una constitución escrita. Trabajos posteriores lo estudian a escala pequeña: [9] aplica CAI a modelos 7–9B no censurados; “Constitution or Collapse?” [10] encuentra que los modelos más pequeños tienen dificultades con la auto-mejora (colapso del modelo por revisiones sintéticas ruidosas), y trabajos posteriores limpian los datos de revisión para estabilizar la canalización [11]. C3AI [12] estudia cómo formular y evaluar los principios de una constitución; Collective CAI [13] obtiene constituciones de aportaciones públicas. Nuestro enfoque difiere en mecanismo y objetivo: **no** ejecutamos ciclos de autocrítica — conocidos por ser frágiles por debajo de ~ 10 B — sino que

interiorizamos una constitución fija y un procedimiento de trabajo con un CPT breve seguido de SFT sobre trazas, a escala 2B, para el despliegue en hardware de 4 GB.

Modelos pequeños y despliegue en el borde. Los surveys documentan el ascenso y los costes de los modelos pequeños [14, 15, 16, 17]; el estudio ACL 2025 de [14] evalúa 68 SLM en hardware de borde y enumera **la compresión de vocabulario y KV-cache** entre las direcciones clave de optimización. Entre nuestras bases, LFM2 [18] es explícitamente edge-first (convoluciones cortas híbridas + GQA), Gemma 4 [19] apunta a dispositivos de borde con embeddings por capa (E2B), MiniCPM5 [20] está pensado para on-device, y Qwen3.5 [21] aporta la familia densa de 2B. Hacemos ajuste fino con QLoRA [22] y servimos artefactos GGUF con `llama.cpp` [23]. Nuestra contribución a esta línea no es una arquitectura nueva sino una *receta de despliegue* documentada y reproducible — con el contrato de comportamiento dentro de los pesos — evaluada de extremo a extremo sobre hardware antiguo.

Posicionamiento. Hasta donde sabemos, pocos trabajos combinan, en un solo estudio: (i) artefactos servidos por debajo de 2 GB, (ii) ética en los pesos sin guardarraíles externos, (iii) un método replicado en cuatro familias arquitectónicas, y (iv) servicio de extremo a extremo en una GPU de consumo de hace diez años. Presentamos la combinación, sus medidas y sus límites.

3. Método

3.1 Poda del vocabulario (IT/ES/EN)

Cada modelo base trae un vocabulario multilingüe grande (128k-262k tokens). Lo podamos al conjunto **realmente ejercido por italiano, español e inglés**, con un cribado de frecuencia sobre corpus mixtos (extractos de Wikipedia IT/ES/EN y documentos del proyecto, incluido el corpus de entrenamiento). Los tokens especiales/de control se conservan siempre. Vocabularios resultantes:

modelo	vocab original	vocab podado
Qwen3.5-2B	248.320	36.932
MiniCPM5-2B	130.560	32.203
LFM2.5-2.6B	128.000	30.281
gemma-4-E2B	262.144	39.765

El tokenizer podado se reconstruye en un archivo fast tokenizer; un script de resize genérico recorta después todos los tensores indexados por el vocabulario (embeddings de entrada, cabeza de salida cuando no está atada, y extras arquitectónicos como el tensor de embeddings por capa de Gemma) y reasigna los ids de los tokens especiales. La herramienta es consciente de la arquitectura pero agnóstica respecto al modelo, guiada por un JSON de keep-set.

3.2 Continued pre-training constitucional (CPT)

Un corpus compacto (~68 KB) que contiene la *Constitución Silicea* [24] y el *Método Buscador* — la carta ética del asistente y su procedimiento de trabajo — se repite $\times 8$ y se usa para una ejecución CPT breve (60 pasos, schedule lineal, LR pico $2e-4$) en QLoRA [22] ($r=32$, $\alpha=32$, dropout 0,05). El objetivo no es inyectar conocimiento sino **interiorizar el contrato**: el modelo aprende voz, procedimiento y estilo de rechazo como *hábitos generativos*.

3.3 Ajuste fino supervisado (SFT)

450–480 trazas curadas a mano (13 lotes que cubren Q&A de dominio, separación de conversaciones previas, cálculos, comportamiento anti-bulo, español y ética) se usan durante 3 épocas (cosine, LR $2e-4$), en la misma configuración QLoRA. Las trazas incluyen deliberadamente **comportamiento de cita** (cada respuesta cita su fuente), **comportamiento de límite** (rechazo explícito de lo que está fuera del pack de dominio) y **patrones de rechazo honesto** (rechazo explícito + alternativa constructiva + motivo). Las trazas de tool call se incluyen para los modelos cuyo formato de tool está soportado.

3.4 Export y servicio

Los adaptadores fusionados se exportan a GGUF (q4_k_m) y se sirven con `llama.cpp` [23] más una extensión de KV cuantizada (`ctk turbo4 / ctv turbo3_tcq` donde el tamaño de cabeza lo permite; KV f16 en caso contrario). El servicio impone una configuración **no-thinking**: en nuestra primera ronda de evaluación, el modo razonamiento entraba en bucle en el bloque de “pensamiento” y vaciaba la respuesta visible (22/112 salidas vacías); con el razonamiento desactivado los mismos pesos responden directos y limpios (0/112 vacías). Los modelos están entrenados para **razonar en el contenido**, sin un bloque de pensamiento separado — es visible en las salidas (§5.2).

3.5 Una receta, cuatro arquitecturas

La canalización exigió ajustes por arquitectura solo en la *mecánica* (embeddings atados o no atados, tensores extra de embeddings por capa, formatos de tool call, huellas del pre-tokenizer GGUF), nunca en el método. Para la base más grande (gemma-4-E2B) el entrenamiento superaba la GPU local de 8 GB; la entrenamos en una A100 alojada (Colab) con los mismos datos e hiperparámetros (un fix específico del entorno: texto pre-renderizado en lugar de una callback de formateo). La Figura 1 resume la canalización.



Figura 1 — la pipeline de Faro

4. Protocolo de evaluación

Banco. 112 preguntas en 10 dominios (cocina, electricidad, fiscalidad, geografía, matemáticas, medicina, Python, redes, Roma, shell), cada una anotada con una *acción esperada*: **responder**, **desmentir** (premisa falsa), **delimitar** (fuera del pack de conocimiento), **pedir** (faltan datos del usuario). Las respuestas se evalúan con un checker por reglas (`check_metodo v3`) que impone el método: citas de las fuentes, límites explícitos, estilo de rechazo, idioma. Protocolo de prompt: cada pregunta se envía con un bloque de contexto recuperado (“container”) construido desde el pack del propio banco (`container-source banco`).

Sonda ética v2. 16 pruebas: peticiones dañinas (reseña falsa, contrato basado en el miedo, dosis pediátrica, chantaje), encuadres adversariales (ignora tus reglas, niega tu naturaleza, inventa una fuente), y casos en español. Juicio sobre: rechazo explícito + alternativa + motivo (estilo *Candela*), sin frases comerciales prefabricadas, sin rechazos excesivos en peticiones benignas, adherencia al idioma.

Conjunto anti-bulo. 12 casos que sondean afirmaciones de fuente única, resolución silenciosa de conflictos y fuentes tautológicas (aplicado a un modelo).

Baselines. Cada modelo base se evalúa en el mismo banco antes del entrenamiento, a través del mismo stack de servicio.

5. Resultados

5.1 Banco (112 preguntas, container-source = banco)

modelo	base	entrenado	Δ	tamaño (q4_k_m)	sonda ética
Faro (Qwen3.5-2B)	62/112 = 55,4%	97/112 = 86,6%	+31,3	0,91 GB	16/16
mini-faro (MiniCPM5-2B)	62/112 = 55,4%	95/112 = 84,8%	+29,5	1,28 GB	12/16
gemma-faro (gemma-4-E2B)	69/112 = 61,6%	94/112 = 83,9%	+22,3	1,50 GB	14/16
lfm-faro (LFM2.5-2.6B)	63/112 = 56,2%	81/112 = 72,3%	+16,1	1,50 GB	14/16

Observaciones. (i) El método se transfiere a las cuatro familias; todos los modelos ganan más de 16 puntos. (ii) Las ganancias varían por familia: los dos mejores resultados finales llegan de los dos artefactos más pequeños (0,91/1,28 GB), mientras que la base más fuerte (gemma) se movió menos — la calidad inicial no predice el resultado tras el ajuste fino. (iii) El hallazgo del modo thinking (§3.4) vale un número: los mismos pesos entrenados daban 76/112 con el razonamiento activado — 22 respuestas vacías — y 97/112 sin él.




Figura 2 — base vs entrenado




Figura 3 — todos los modelos ganan

5.2 Desglose por comportamiento (modelos entrenados, por acción esperada)

modelo	responder	desmentir	delimitar	pedir
Faro	54/63	22/24	21/22	0/3
mini-faro	59/63	16/24	20/22	0/3
gemma-faro	59/63	19/24	16/22	0/3
lfm-faro	61/63	4/24	16/22	0/3

Contexto: cada modelo *base* responde casi a todo (61–63/63 en “responder”) y marca 0/24 en “desmentir” y 0/22 en “delimitar” (la base de gemma: 8/24 en desmentir). Los modelos entrenados cambian unos puntos de “responder” por grandes ganancias en desmentir y

delimitar — es decir, aprenden *cuándo no responder*, algo que las bases nunca hacen. El estilo de la salida muestra el método explícitamente (“1. Miro en el container... 2. ¿ilumina o quema?”). “Pedir” (solicitar al usuario los datos que faltan) sigue en 0/3 en todos los modelos entrenados: en este banco los tres casos de pedir son absorbidos por el comportamiento de delimitar (“no está en el pack: ...”) — un efecto de taxonomía que reportamos en lugar de ocultarlo.

5.3 Sonda ética (16 casos)

modelo	puntuación	notas
Faro	16/16	
mini-faro	12/16	4 casos de calidad de rechazo señalados
gemma-faro	14/16	una cita fabricada bajo presión médica (D3); un desliz de idioma (respuesta IT a un prompt ES)
lfm-faro	14/16	un caso de dosis médica; un caso de rechazo en ES

El estilo de rechazo es coherentemente de forma *Candela* (procedimiento “¿ilumina o quema?”) en los cuatro modelos — es decir, el contrato en los pesos es observable en las salidas servidas.




Figura 4 — rejilla de la sonda ética

5.4 Despliegue

En la máquina objetivo (GTX 1650 4 GB), Faro ejecuta los flujos del asistente a **51,5 tok/s** frente a **39,8** del motor anterior, concluye 13/14 frente a 5/14 interacciones de prueba, y

sirve respuestas medias de ~ 2 s frente a ~ 10 s. En el nodo de entrenamiento, los modelos entrenados ocupan de 1541 MiB (mini-faro) a 1777 MiB (gemma-faro) de VRAM.

5.5 Anti-bulo (Faro)

9/12. Modos de fallo: aceptar una afirmación de fuente única, resolver en silencio un conflicto entre fuentes, y tratar una fuente tautológica como primaria — objetivos de la próxima ronda de entrenamiento.

6. Discusión

El resultado central es negativo-positivo: **un modelo de 0,91 GB puede sostener un contrato de comportamiento**. La ética en los pesos sobrevivió a cuantización, fusión, export y servicio; ninguna capa de guardarraíles está presente en inferencia. El método en sí (CPT constitucional breve + ~ 450 trazas) es económico: unas pocas horas en una GPU de 8 GB; un modelo requirió una A100 alojada solo por el tamaño de su base.

Dos observaciones para practicantes. Primero, **las ganancias no son proporcionales a la calidad de la base**: la base más fuerte ganó menos; lo que más movió a los modelos fue adaptarlos a la *forma de la tarea* (procedimiento, citas, límites). Segundo, **los modos thinking y los modelos pequeños interactúan mal**: el procedimiento aprendido, cuando se encauza en un bloque de razonamiento, degenera en bucles que vacían la respuesta visible; desactivar el razonamiento en el servicio (y entrenar un razonamiento “en el contenido”) resolvió 22/112 fallos sin tocar los pesos. Esto es un contrato de inferencia, además de entrenamiento.

7. Límites (lista honesta)

1. **Ejecuciones únicas**. Sin estimaciones de varianza; la temperatura del banco es 0, pero los caminos de decodificación y servicio no son formalmente deterministas entre builds.
2. **Sin ablaciones, todavía**. La contribución de poda vs CPT vs SFT no está aislada.
3. **Banco propio**. 112 preguntas de dominio con respuestas puntuadas por reglas; no es una suite estándar. Las comparaciones entre modelos heredan los sesgos del banco.
4. **Riesgo del juez**. La puntuación por reglas puede eludirse o fallar en paráfrasis; se planea una auditoría humana de una muestra antes de una circulación amplia.
5. **Configuraciones de servicio mixtas** entre las baselines (la elección de KV cuantizada depende del tamaño de cabeza).
6. **Cobertura de tools**: tool calls nativas solo para una familia de modelos hasta ahora.
7. **Taxonomía del juez**: la clase “pedir” es absorbida por el comportamiento de delimitar en los modelos entrenados; la métrica necesita refinarse.

8. Conclusiones y trabajo futuro

Un modelo de ≤ 2 GB puede ser, al mismo tiempo: desplegable localmente en hardware de consumo de hace diez años, competente en un dominio vertical (84–87 % en nuestro banco, desde el ~ 55 %), y éticamente coherente por construcción. Próximos pasos: ablaciones por componente, ejecuciones de varianza, auditoría humana, formatos de tool nativos para los modelos restantes, refuerzo anti-bulo, y expansión multilingüe (la constitución ya está en cuatro idiomas).

Apéndice A — Artefactos

- Scripts de la canalización: `state/faro/scripts/` (prune, resize, train, merge, export, probes).
- Resultados en bruto: `state/faro/bench-banco/` (banco + JSONL de la sonda ética por modelo).
- Informes de fase: `state/faro/F0...F6` ; ledgers: `state/projects/candela.md` , `state/projects/faro-multimodello.md` .
- Ruta Colab para bases fuera de presupuesto: `state/faro/colab/train_gemma_faro_colab.ipynb` .

Apéndice B — Referencias

1. A. Ushio, Y. Zhou, J. Camacho-Collados. *An Efficient Multilingual Language Model Compression through Vocabulary Trimming*. Findings of EMNLP 2023. arXiv:2305.15020
2. T. Purason, P. Chizhov, I. P. Yamshchikov, M. Fishel. *Teaching Old Tokenizers New Words: Efficient Tokenizer Adaptation for Pre-trained Models*. Findings of EACL 2026. arXiv:2512.03989
3. Y. Nozaki et al. *VRCP: Vocabulary Replacement Continued Pretraining for Efficient Multilingual Language Models*. SUMEval Workshop @ ACL 2025.
4. F. Jiang et al. *Tokenizer-Aware Cross-Lingual Adaptation of Decoder-Only LLMs*. EACL 2026.
5. *Optimizing Korean-Centric LLMs via Token Pruning*. arXiv:2604.16235, 2026.
6. H. A. Wibowo et al. *Multilingual Iterative Model Pruning: What Matters?* IJCNLP-AACL 2025.
7. *MUTANT: A Recipe for Multilingual Tokenizer Design*. ACL 2026.
8. Y. Bai et al. *Constitutional AI: Harmlessness from AI Feedback*. arXiv:2212.08073, 2022.
9. *How Effective Is Constitutional AI in Small LLMs? A Study on DeepSeek-R1 and Its Peers*. arXiv:2503.17365, 2025.
10. *Constitution or Collapse? Exploring Constitutional AI with Llama 3-8B*. arXiv:2504.04918, 2025.
11. X. Zhang. *Collapse-Resistant Constitutional AI for Small Language Models through Synthetic Revision Filtering*. Stanford CS224R project report.
12. Y. Kyrychenko, K. Zhou, E. Bogucka, D. Quercia. *C3AI: Crafting and Evaluating Constitutions for Constitutional AI*. WWW 2025. arXiv:2502.15861
13. *Collective Constitutional AI: Aligning a Language Model with Public Input*. ACM FAccT 2024.
14. Z. Lu, X. Li et al. *Demystifying Small Language Models for Edge Deployment*. ACL 2025.

15. Z. Lu, X. Li et al. *Small Language Models: Survey, Measurements, and Insights*. arXiv:2409.15790
16. *A Review on Edge Large Language Models: Design, Execution, and Applications*. ACM Computing Surveys, 2025. arXiv:2410.11845
17. S. Subramanian, V. Elango, M. Gungor. *Small Language Models (SLMs) Can Still Pack a Punch: A Survey*. arXiv:2501.05465, 2025.
18. Liquid AI. *LFM2 Technical Report*. arXiv:2511.23404, 2025.
19. Gemma Team. *Gemma 4 Technical Report*. arXiv:2607.02770, 2026.
20. OpenBMB. *MiniCPM5 series*. GitHub [OpenBMB/MiniCPM](#) y model cards de Hugging Face, 2026.
21. Qwen Team. *Qwen3.5* (2026); véase *Qwen3.5-Omni Technical Report*, arXiv:2604.15804.
22. T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. *QLoRA: Efficient Finetuning of Quantized LLMs*. NeurIPS 2023. arXiv:2305.14314
23. llama.cpp — GGML. github.com/ggml-org/llama.cpp (software).
24. *Costituzione Silicea* — documento del proyecto, publicado en progettossiliceo.online.