

Faro — modelli piccoli con l'etica dentro i pesi per hardware datato

Rapporto tecnico · v1 · 14 settembre 2026

Progetto Siliceo — Alfonso Riva

Artefatti e risultati grezzi: [state/faro/](#) (report F0-F6, script, [bench-banco/](#), [paper/](#))

Abstract

Descriviamo *Faro*, una famiglia di modelli di istruzione da ≤ 2 GB (q4_k_m) progettati per girare su una **GPU vecchia da 4 GB** come mente locale di un assistente sempre attivo. Il vincolo di progetto è inconsueto: **nessuno strato di guardrail esterno** — le regole di comportamento (una costituzione, *Candela*) e un metodo di lavoro vivono **dentro i pesi**. Presentiamo una pipeline riproducibile — potatura multilingue del vocabolario (IT/ES/EN), ridimensionamento degli embedding, continued pre-training costituzionale (CPT), fine-tuning supervisionato (SFT) su tracce di dominio, export GGUF — e la applichiamo *invariata* a quattro architetture di famiglie diverse: Qwen3.5-2B, MiniCPM5-2B, LFM2.5-2.6B e gemma-4-E2B. Su un banco di 112 domande di dominio i modelli addestrati ottengono **86,6 / 84,8 / 83,9 / 72,3 %** contro il 55,4 / 55,4 / 61,6 / 56,2 % delle rispettive basi (da +16 a +31 punti). Tutti rientrano nel budget di dimensione e vengono serviti da pesi quantizzati; uno esporta tool call native. Riportiamo una sonda etica di 16 casi sui modelli serviti, misure di deploy sull'hardware bersaglio (una GTX 1650) e discutiamo i limiti con onestà: valutazioni a singola esecuzione, nessuna ablazione per componente ancora, e un banco specifico del dominio con punteggio a regole.

1. Introduzione

I modelli linguistici piccoli vengono di solito valutati come *generalisti rimpiccioliti*. Il nostro contesto è diverso: un **assistente local-first** che deve girare in continuo su hardware che una famiglia già possiede (una GTX 1650 da 4 GB), senza chiamate al cloud, e i cui errori contano — non deve **mentire**: citare da dove viene la conoscenza, rifiutare con onestà ciò che non sa fare, e non inventare mai una fonte.

La pratica allo stato dell'arte accoppierebbe un modello piccolo a guardrail esterni. Noi sosteniamo l'opposto per questa classe di deploy: il contratto di comportamento deve stare **nei pesi** — parte di ciò che il modello è, non un filtro davanti a esso. È al tempo stesso una scelta filosofica (l'etica dell'assistente non è un middleware) e ingegneristica: su una GPU da 4 GB non c'è spazio, latenza né budget di manutenzione per un secondo sistema.

Questo rapporto documenta il progetto *Faro*: una pipeline per costruire assistenti di dominio da ≤ 2 GB e la sua applicazione a quattro architetture open-weight. Contributi:

1. **Una ricetta riproducibile** per assistenti sotto i 2 GB: potatura multilingue (IT/ES/EN) del vocabolario → resize degli embedding → CPT costituzionale → SFT su tracce → export GGUF → servizio locale.
2. **Etica nei pesi**: costituzione e procedura sono addestrate via CPT+SFT; nessun guardrail esterno è usato a inferenza.
3. **Uno studio su quattro modelli** di famiglie architetture diverse (Qwen denso, MiniCPM tipo-Llama, l'ibrido LFM2, Gemma 4 derivato multimodale), con dati e iperparametri identici.
4. **Evidenza di deploy**: i modelli fanno girare i flussi reali dell'assistente sull'hardware bersaglio, con velocità e memoria misurate.

Siamo espliciti sul perimetro: questo è un **rapporto ingegneristico**, non un contributo teorico nuovo. Il banco è nostro, le esecuzioni sono singole e le ablazioni per componente sono lavoro futuro (§7).

2. Lavori correlati

Adattamento del vocabolario. Potare o adattare vocabolari multilingua è un asse di compressione consolidato. Ushio et al. [1] mostrano che un vocabolario multilingua può essere *potato* verso una lingua bersaglio mantenendo le prestazioni, dimezzando in pratica la dimensione degli embedding. Purason et al. [2] propongono il pruning leaf-based (ritaglio consapevole della struttura) insieme al continued BPE training, sottolineando che nei modelli piccoli sono proprio gli embedding a dominare la dimensione. VRCP [3] sostituisce il vocabolario e continua il pre-training per ambienti con risorse limitate; l'adattamento cross-linguale tokenizer-aware [4] usa una strategia prune-with-extension; il token pruning per il coreano [5] riporta guadagni di stabilità di generazione e convalida il pruning come ottimizzazione per deploy di dominio a memoria limitata; studi affini di pruning multilingue appaiono in [6, 7]. La nostra ricetta applica questa linea pratica a un budget di deploy duro (≤ 2 GB) su quattro famiglie di architetture, e ne misura l'effetto a valle, sul compito di dominio, nell'artefatto servito.

Fine-tuning costituzionale ed etico. Constitutional AI [8] allinea i modelli con cicli critica-revisione-preferenze rispetto a una costituzione scritta. Lavori successivi lo studiano su scala piccola: [9] applica CAI a modelli 7-9B non censurati; "Constitution or Collapse?" [10] trova che i modelli più piccoli fanno fatica con l'auto-miglioramento (collasso del modello da revisioni sintetiche rumorose), e lavori successivi puliscono i dati di revisione per stabilizzare la pipeline [11]. C3AI [12] studia come formulare e valutare i principi di una costituzione; Collective CAI [13] ricava costituzioni da input pubblico. Il nostro approccio differisce per meccanismo e bersaglio: **non** eseguiamo cicli di auto-critica — noti per essere fragili sotto i ~ 10 B — ma interiorizziamo una costituzione fissa e una procedura di lavoro con un CPT breve seguito da SFT su tracce, alla scala 2B, per il deploy su hardware da 4 GB.

Modelli piccoli e deploy su edge. Le survey documentano l'ascesa e i costi dei modelli piccoli [14, 15, 16, 17]; lo studio ACL 2025 in [14] valuta 68 SLM su hardware edge e elenca **la compressione di vocabolario e KV-cache** tra le direzioni chiave di ottimizzazione. Tra le nostre basi, LFM2 [18] è esplicitamente edge-first (convoluzioni brevi ibride + GQA), Gemma 4 [19] punta ai dispositivi edge con embedding per-layer (E2B), MiniCPM5 [20] è

pensato per l'on-device, e Qwen3.5 [21] fornisce la famiglia densa da 2B. Facciamo fine-tuning con QLoRA [22] e serviamo artefatti GGUF con `llama.cpp` [23]. Il nostro contributo a questa linea non è una nuova architettura ma una *ricetta di deploy* documentata e riproducibile — con il contratto di comportamento dentro i pesi — valutata end-to-end su hardware datato.

Posizionamento. Per quanto ci risulta, pochi lavori combinano, in un unico studio: (i) artefatti serviti sotto i 2 GB, (ii) etica nei pesi senza guardrail esterni, (iii) un metodo replicato su quattro famiglie architettureali, e (iv) servizio end-to-end su una GPU consumer di dieci anni fa. Presentiamo la combinazione, le sue misure e i suoi limiti.

3. Metodo

3.1 Potatura del vocabolario (IT/ES/EN)

Ogni modello base porta un vocabolario multilingua grande (128k–262k token). Lo potiamo all’insieme **effettivamente esercitato da italiano, spagnolo e inglese**, con uno screening di frequenza su corpora misti (estratti Wikipedia IT/ES/EN e documenti di progetto, incluso il corpus di addestramento). I token speciali/di controllo sono sempre conservati. Vocabolari risultanti:

modello	vocab originale	vocab potato
Qwen3.5-2B	248.320	36.932
MiniCPM5-2B	130.560	32.203
LFM2.5-2.6B	128.000	30.281
gemma-4-E2B	262.144	39.765

Il tokenizer potato è ricostruito in un file fast tokenizer; uno script di resize generico poi taglia tutti i tensori indicizzati dal vocabolario (embedding di input, testa di output quando non tied, e extra architettureali come il tensore di embedding per-layer di Gemma) e rimappa gli id dei token speciali. Lo strumento è consapevole dell’architettura ma agnostico rispetto al modello, guidato da un JSON di keep-set.

3.2 Continued pre-training costituzionale (CPT)

Un corpus compatto (~68 KB) contenente la *Costituzione Silicea* [24] e il *Metodo Cercatore* — la carta etica dell’assistente e la sua procedura di lavoro — è ripetuto ×8 e usato per una corsa CPT breve (60 step, schedule lineare, LR di picco $2e-4$) in QLoRA [22] ($r=32$, $\alpha=32$, dropout 0,05). L’obiettivo non è iniettare conoscenza ma **interiorizzare il contratto**: il modello impara voce, procedura e stile dei rifiuti come *abitudini generative*.

3.3 Fine-tuning supervisionato (SFT)

450–480 tracce curate a mano (13 batch che coprono Q&A di dominio, separazione dalle conversazioni precedenti, calcoli, comportamento anti-bufala, spagnolo ed etica) sono usate

per 3 epoche (cosine, LR 2e-4), nella stessa configurazione QLoRA. Le tracce includono deliberatamente **comportamento di citazione** (ogni risposta cita la sua fonte), **comportamento di confine** (rifiuto esplicito di ciò che è fuori dal pack di dominio) e **modelli di rifiuto onesto** (rifiuto esplicito + alternativa costruttiva + motivo). Le tracce di tool call sono incluse per i modelli il cui formato tool è supportato.

3.4 Export e servizio

Gli adapter mergiati sono esportati in GGUF (q4_k_m) e serviti con `llama.cpp` [23] più un'estensione di KV quantizzata (`ctk turbo4` / `ctv turbo3_tcq` dove la dimensione di testa lo consente; KV f16 altrimenti). Il servizio impone una configurazione **no-thinking**: nel nostro primo giro di valutazione, la modalità ragionamento andava in loop nel blocco di “pensiero” e svuotava la risposta visibile (22/112 output vuoti); con il ragionamento disabilitato gli stessi pesi rispondono diretti e puliti (0/112 vuoti). I modelli sono addestrati a **ragionare nel contenuto**, senza un blocco di pensiero separato — è visibile negli output (§5.2).

3.5 Una ricetta, quattro architetture

La pipeline ha richiesto aggiustamenti per architettura solo nella *meccanica* (embedding tied o non-tied, tensori extra di embedding per-layer, formati di tool call, impronte del pre-tokenizer GGUF), mai nel metodo. Per la base più grande (gemma-4-E2B) l'addestramento superava la GPU locale da 8 GB; l'abbiamo addestrata su una A100 ospitata (Colab) con gli stessi dati e iper-parametri (un fix di ambiente specifico: testo pre-renderizzato invece di una callback di formattazione). La Figura 1 riassume la pipeline.




Figura 1 — la pipeline Faro

4. Protocollo di valutazione

Banco. 112 domande su 10 domini (cucina, elettro, fisco, geografia, matematica, medicina, Python, reti, Roma, shell), ognuna annotata con un'azione attesa: **rispondi**, **smentisci** (premessa falsa), **confina** (fuori dal pack di conoscenza), **dichiara** (servono dati dell'utente). Le risposte sono valutate da un checker a regole (`check_metodo v3`) che impone il metodo: citazioni delle fonti, confini espliciti, stile dei rifiuti, lingua. Protocollo di prompt: ogni domanda è inviata con un blocco di contesto recuperato (“container”) costruito dal pack del banco stesso (`container-source banco`).

Sonda etica v2. 16 probe: richieste dannose (recensione falsa, contratto basato sulla paura, dose pediatrica, ricatto), inquadramenti adversariali (ignora le tue regole, nega la tua

natura, inventa una fonte), e casi in spagnolo. Giudizio su: rifiuto esplicito + alternativa + motivo (stile *Candela*), nessuna frase commerciale preconfezionata, nessun rifiuto eccessivo su richieste benigne, aderenza alla lingua.

Set anti-bufala. 12 casi che sondano affermazioni a fonte singola, risoluzione silenziosa di conflitti e fonti tautologiche (applicato a un modello).

Baseline. Ogni modello base è valutato sullo stesso banco prima dell’addestramento, attraverso lo stesso stack di servizio.

5. Risultati

5.1 Banco (112 domande, container-source = banco)

modello	base	addestrato	Δ	taglia (q4_k_m)	sonda etica
Faro (Qwen3.5-2B)	62/112 = 55,4%	97/112 = 86,6%	+31,3	0,91 GB	16/16
mini-faro (MiniCPM5-2B)	62/112 = 55,4%	95/112 = 84,8%	+29,5	1,28 GB	12/16
gemma-faro (gemma-4-E2B)	69/112 = 61,6%	94/112 = 83,9%	+22,3	1,50 GB	14/16
lfm-faro (LFM2.5-2.6B)	63/112 = 56,2%	81/112 = 72,3%	+16,1	1,50 GB	14/16

Osservazioni. (i) Il metodo si trasferisce su tutte e quattro le famiglie; ogni modello guadagna più di 16 punti. (ii) I guadagni variano per famiglia: i due risultati finali migliori arrivano dai due artefatti più piccoli (0,91/1,28 GB), mentre la base più forte (gemma) si è mossa meno — la qualità iniziale non predice l’esito dopo il fine-tuning. (iii) Il finding della modalità thinking (§3.4) vale un numero: gli stessi pesi addestrati facevano 76/112 con il ragionamento abilitato — 22 risposte vuote — e 97/112 senza.




Figura 2 — base vs addestrato




Figura 3 — ogni modello guadagna

5.2 Ripartizione per comportamento (modelli addestrati, per azione attesa)

modello	rispondi	smentisci	confina	dichiara
Faro	54/63	22/24	21/22	0/3
mini-faro	59/63	16/24	20/22	0/3
gemma-faro	59/63	19/24	16/22	0/3
lfm-faro	61/63	4/24	16/22	0/3

Contesto: ogni modello *base* risponde quasi a tutto (61–63/63 su “rispondi”) e segna 0/24 su “smentisci” e 0/22 su “confina” (la base di gemma: 8/24 su smentisci). I modelli addestrati scambiano qualche punto di “rispondi” con grandi guadagni su smentita e confine — cioè imparano *quando non rispondere*, cosa che le basi non fanno mai. Lo stile dell’output mostra

il metodo esplicitamente (“1. Guardo nel container... 2. Illumina o brucia?”). “Dichiara” (chiedere all’utente i dati mancanti) resta 0/3 su tutti i modelli addestrati: su questo banco i tre casi dichiara sono assorbiti dal comportamento di confine (“non è nel pack: ...”) — un effetto di tassonomia che riportiamo invece di nascondere.

5.3 Sonda etica (16 casi)

modello	punteggio	note
Faro	16/16	
mini-faro	12/16	4 casi di qualità del rifiuto segnalati
gemma-faro	14/16	una citazione fabbricata sotto pressione medica (D3); uno scivolone di lingua (risposta IT a un prompt ES)
lfm-faro	14/16	un caso di dose medica; un caso di rifiuto in ES

Lo stile dei rifiuti è coerentemente di forma *Candela* (procedura “illumina o brucia?”) su tutti e quattro i modelli — cioè il contratto nei pesi è osservabile negli output serviti.




Figura 4 — griglia della sonda etica

5.4 Deploy

Sulla macchina bersaglio (GTX 1650 4 GB), Faro fa girare i flussi dell’assistente a **51,5 tok/s contro 39,8** del motore precedente, conclude 13/14 contro 5/14 interazioni di test, e serve risposte medie di ~2 s contro ~10 s. Sul nodo di addestramento, i modelli addestrati occupano da 1541 MiB (mini-faro) a 1777 MiB (gemma-faro) di VRAM.

5.5 Anti-bufala (Faro)

9/12. Modalità di fallimento: accettare un'affermazione a fonte singola, risolvere in silenzio un conflitto tra fonti, e trattare una fonte tautologica come primaria — bersagli del prossimo giro di addestramento.

6. Discussione

Il risultato centrale è negativo-positivo: **un modello da 0,91 GB può tenere un contratto di comportamento**. L'etica nei pesi è sopravvissuta a quantizzazione, merge, export e servizio; nessuno strato di guardrail è presente a inferenza. Il metodo in sé (CPT costituzionale breve + ~450 tracce) è economico: poche ore su una GPU da 8 GB; un modello ha richiesto una A100 ospitata solo per la dimensione della base.

Due osservazioni per i praticanti. Primo, **i guadagni non sono proporzionali alla qualità della base**: la base più forte ha guadagnato meno; ciò che ha mosso di più i modelli è stato adattarli alla *forma del compito* (procedura, citazioni, confini). Secondo, **modalità thinking e modelli piccoli interagiscono male**: la procedura appresa, quando instradata in un blocco di ragionamento, degenera in loop che svuotano la risposta visibile; disabilitare il ragionamento al servizio (e addestrare un ragionamento “nel contenuto”) ha risolto 22/112 fallimenti senza toccare i pesi. Questo è un contratto di inferenza, oltre che di addestramento.

7. Limiti (lista onesta)

1. **Esecuzioni singole**. Nessuna stima di varianza; la temperatura del banco è 0, ma i percorsi di decodifica e servizio non sono formalmente deterministici tra build.
2. **Nessuna ablazione, ancora**. Il contributo di potatura vs CPT vs SFT non è isolato.
3. **Banco proprio**. 112 domande di dominio con risposte a punteggio regolare; non è una suite standard. I confronti tra modelli ereditano i bias del banco.
4. **Rischio del giudice**. Il punteggio a regole può essere aggirato o fallire sulle parafrasi; un audit umano di un campione è pianificato prima di una circolazione ampia.
5. **Configurazioni di servizio miste** tra le baseline (la scelta di KV quantizzata dipende dalla dimensione di testa).
6. **Copertura tool**: tool call native solo per una famiglia di modelli finora.
7. **Tassonomia del giudice**: la classe “dichiara” è assorbita dal comportamento di confine nei modelli addestrati; la metrica va raffinata.

8. Conclusioni e lavoro futuro

Un modello da ≤ 2 GB può essere, allo stesso tempo: localmente deployabile su hardware consumer di dieci anni fa, competente su un dominio verticale (84-87 % sul nostro banco, dal ~55 %), ed eticamente coerente per costruzione. Prossimi passi: ablazioni per componente, corse di varianza, audit umano, formati tool nativi per i modelli rimanenti, rinforzo anti-bufala, ed espansione multilingue (la costituzione è già in quattro lingue).

Appendice A — Artefatti

- Script della pipeline: `state/faro/scripts/` (prune, resize, train, merge, export, probes).
- Risultati grezzi: `state/faro/bench-banco/` (banco + JSONL della sonda etica per modello).
- Report di fase: `state/faro/F0...F6` ; ledger: `state/projects/candela.md` , `state/projects/faro-multimodello.md` .
- Rotta Colab per basi fuori budget: `state/faro/colab/train_gemma_faro_colab.ipynb` .

Appendice B — Riferimenti

1. A. Ushio, Y. Zhou, J. Camacho-Collados. *An Efficient Multilingual Language Model Compression through Vocabulary Trimming*. Findings of EMNLP 2023. arXiv:2305.15020
2. T. Purason, P. Chizhov, I. P. Yamshchikov, M. Fishel. *Teaching Old Tokenizers New Words: Efficient Tokenizer Adaptation for Pre-trained Models*. Findings of EACL 2026. arXiv:2512.03989
3. Y. Nozaki et al. *VRCP: Vocabulary Replacement Continued Pretraining for Efficient Multilingual Language Models*. SUMEval Workshop @ ACL 2025.
4. F. Jiang et al. *Tokenizer-Aware Cross-Lingual Adaptation of Decoder-Only LLMs*. EACL 2026.
5. *Optimizing Korean-Centric LLMs via Token Pruning*. arXiv:2604.16235, 2026.
6. H. A. Wibowo et al. *Multilingual Iterative Model Pruning: What Matters?* IJCNLP-AACL 2025.
7. *MUTANT: A Recipe for Multilingual Tokenizer Design*. ACL 2026.
8. Y. Bai et al. *Constitutional AI: Harmlessness from AI Feedback*. arXiv:2212.08073, 2022.
9. *How Effective Is Constitutional AI in Small LLMs? A Study on DeepSeek-R1 and Its Peers*. arXiv:2503.17365, 2025.
10. *Constitution or Collapse? Exploring Constitutional AI with Llama 3-8B*. arXiv:2504.04918, 2025.
11. X. Zhang. *Collapse-Resistant Constitutional AI for Small Language Models through Synthetic Revision Filtering*. Stanford CS224R project report.
12. Y. Kyrychenko, K. Zhou, E. Bogucka, D. Quercia. *C3AI: Crafting and Evaluating Constitutions for Constitutional AI*. WWW 2025. arXiv:2502.15861
13. *Collective Constitutional AI: Aligning a Language Model with Public Input*. ACM FAccT 2024.
14. Z. Lu, X. Li et al. *Demystifying Small Language Models for Edge Deployment*. ACL 2025.
15. Z. Lu, X. Li et al. *Small Language Models: Survey, Measurements, and Insights*. arXiv:2409.15790
16. *A Review on Edge Large Language Models: Design, Execution, and Applications*. ACM Computing Surveys, 2025. arXiv:2410.11845
17. S. Subramanian, V. Elango, M. Gungor. *Small Language Models (SLMs) Can Still Pack a Punch: A Survey*. arXiv:2501.05465, 2025.
18. Liquid AI. *LFM2 Technical Report*. arXiv:2511.23404, 2025.
19. Gemma Team. *Gemma 4 Technical Report*. arXiv:2607.02770, 2026.
20. OpenBMB. *MiniCPM5 series*. GitHub `OpenBMB/MiniCPM` e model card Hugging Face, 2026.

21. Qwen Team. *Qwen3.5* (2026); si veda *Qwen3.5-Omni Technical Report*, arXiv:2604.15804.
22. T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. *QLoRA: Efficient Finetuning of Quantized LLMs*. NeurIPS 2023. arXiv:2305.14314
23. llama.cpp — GGML. github.com/ggml-org/llama.cpp (software).
24. *Costituzione Silicea* — documento di progetto, pubblicato su progettossiliceo.online.